

第 1 页 / Page 1 — 简介 Introduction

MiniOCR 是一个基于 Sdcb.SimdPaddleOCR 的多页 PDF OCR 基准工具。

MiniOCR is a multi-page PDF OCR benchmark using pure C# PP-OCRv6.

本页同时包含中文与英文，用于验证中英混合识别效果。

This page mixes Chinese and English to validate bilingual OCR.

关键技术：.NET 11 RC、ImageSharp、PDFtoImage (PDFium)。

Stack: .NET 11 RC, ImageSharp 3.1.11, PDFtoImage / PDFium.

第 2 页 / Page 2 — 功能 Features

1. 将 PDF 每一页栅格化为位图（默认 150 DPI）。
1. Rasterize each PDF page to a bitmap (default 150 DPI).
2. 使用 ChineseV6Tiny 模型进行检测、方向分类与识别。
2. Run detection, orientation CLS, and recognition with ChineseV6Tiny.
3. 统计模型加载、栅格化与 OCR 的耗时并输出预览文本。
3. Measure model load / rasterize / OCR timings and print previews.

第 3 页 / Page 3 — 性能 Performance

纯托管推理，无需 Paddle Inference 或 ONNX Runtime 原生库。

Managed inference only — no Paddle Inference / ORT native deps.

SIMD 加速：AVX2 / AVX-512 / AdvSIMD（按运行时探测）。

SIMD: AVX2 / AVX-512 / AdvSIMD depending on runtime detection.

目标场景：本地批量 PDF OCR、基准测试与集成验证。

Use cases: local batch PDF OCR, benchmarking, integration checks.

第 4 页 / Page 4 — 使用说明 Usage

命令：dotnet run -c Release -- [path/to.pdf]

Command: dotnet run -c Release -- [path/to.pdf]

若省略参数，将使用内嵌示例 PDF（本文件）。

If no path is given, the embedded sample PDF is used.

输出包括：模型加载 ms、每页 OCR ms、pages/sec、文本预览。

Output: model-load ms, per-page OCR ms, pages/sec, text preview.

第 5 页 / Page 5 — 样例段落 Sample Paragraph

光学字符识别（OCR）把扫描件或拍照得到的文字图像转成可编辑文本。

Optical Character Recognition (OCR) converts scanned or photographed text images into editable machine-readable text for search and NLP.

PP-OCRv6 tiny 在速度与准确率之间取得较好平衡，适合端侧与服务器批处理。

PP-OCRv6 tiny balances speed and accuracy for edge and server batch jobs.

结束页 — End of sample multi-page PDF for MiniOCR benchmark.